

UNIVERSIDAD DEL VALLE DE GUATEMALA
CC3084 - Data Science
Sección 30
Ing. Boris Becerra



Laboratorio 5:
Clasificación de tweets usando minería de texto

Daniel Oswaldo Juárez Herrera
Humberto Alexander de la Cruz
Nicolle Alexandra Gordillo

Guatemala, 27 de agosto del 2026

Repositorio: <https://github.com/nicollegordillo/Mineria-de-Textos-y-analisis-de-sentimiento>

1. Descripción del conjunto de datos (ejercicios 1 y 2)

Se trabajó con train.csv del dataset *Natural Language Processing with Disaster Tweets* de Kaggle, compuesto por 7,613 filas y 5 columnas: id, keyword, location, text y target. El objetivo es clasificar si un tweet se refiere a un desastre real (target = 1) o no (target = 0).


La Tabla 1 resume tipo, faltantes y cardinalidad de cada columna:

Columna	Tipo	Nulos	% nulos	Valores únicos
id	int64	0	0.00	7,613
keyword	object	61	0.80	221
location	object	2,533	33.27	3,341
text	object	0	0.00	7,503
target	int64	0	0.00	2

Los faltantes se concentran casi por completo en location, con un tercio del conjunto sin dato. keyword está prácticamente completa. Nótese que text tiene 7,503 valores únicos frente a 7,613 filas, lo que anticipa el problema de duplicados de la sección 1.2.

1.1 Balance de la variable objetivo

La Figura 1 muestra la distribución de target: 4,342 tweets no-desastre (57.03%) frente a 3,271 de desastre real (42.97%). El desbalance es leve, por lo que no se aplicó sobremuestreo; aun así se reportan precisión, recall y F1 además de la exactitud, y todas las particiones son estratificadas. La línea base trivial de predecir siempre la clase mayoritaria alcanza una exactitud de 0.5703, que es el mínimo que cualquier modelo debe superar.



1.2 Calidad de las etiquetas

Se identificaron 179 tweets con texto duplicado, y entre ellos 18 textos con etiquetas contradictorias: el mismo texto aparece etiquetado como 0 y como 1. Un ejemplo es un tweet sobre #foodscare #offers2go #NestleIndia, que aparece tres veces con dos etiquetas distintas.

Esto no es un error de los anotadores sino un reflejo de la ambigüedad real de la tarea: hay tweets cuya clasificación depende del contexto externo o de la interpretación del anotador. La consecuencia práctica es que existe un techo al desempeño máximo alcanzable, dato relevante al leer las métricas de la sección 5: parte del error del modelo es irreducible.

2. Limpieza y preprocesamiento (ejercicio 3)


2.1 Diagnóstico previo

Antes de decidir qué eliminar se cuantificaron los artefactos del texto crudo. La Tabla 2 cruza esos conteos contra la categoría (promedios por tweet):

Artefacto	No desastre (0)	Desastre real (1)
Caracteres	95.71	108.11
Palabras	14.71	15.17
URLs	0.508	0.770
Menciones @	0.420	0.272
Hashtags #	0.389	0.502
Números	0.240	0.454
Emojis	0.000	0.000
Emoticones ASCII	0.013	0.005
Contiene 911	0.0002	0.0009
Proporción de mayúsculas	0.098	0.102
Signos de exclamación	0.194	0.101

Lectura del diagnóstico (Tabla 2, Figura 2):

Figura 2. Longitud y presencia de URLs según la categoría



- Los tweets de desastre real son más largos (108 vs. 96 caracteres) y traen más URLs (0.77 vs. 0.51 por tweet), consistente con que enlazan notas de prensa. También usan más hashtags y más números, propios del registro noticioso (magnitudes, cifras de víctimas, fechas).
- Los no-desastre traen más menciones @ (0.42 vs. 0.27) y el doble de signos de exclamación, propios de conversación personal y de registro expresivo.
- El 911: el enunciado pide valorar explícitamente si conservarlo. Aparece en solo 4 tweets de 7,613 (3 en desastre real, 1 en no-desastre). Se conservó, mapeándolo al token num911 antes de eliminar el resto de números, porque el costo es nulo y el token es semánticamente pertinente; pero con esa frecuencia no tiene impacto práctico en la clasificación. La respuesta honesta al enunciado es que la decisión resulta irrelevante en este corpus, no que aporte señal.
- Los emojis: el corpus no contiene ni un solo emoji ($n_{\text{emojis}} = 0$ en ambas clases). Todos llegaron corruptos como secuencias del tipo `\x89` por problemas de codificación en el scraping original — visibles en tweets como DT @georgegalloway: RT @Galloway4Mayor: ÛThe.... Sí hay 73 emoticones ASCII (:), :/), ligeramente más frecuentes en la clase no-desastre. Para el modelo se eliminan; se conservan el texto original y los conteos porque en el ejercicio 8 se analizan.

2.2 Pasos aplicados y su justificación

Implementados en la función `limpiar_tweet()`, usando `re`, `html` y `string` de la biblioteca estándar, `NLTK` (`stopwords` y `WordNetLemmatizer`) y `scikit-learn` para la vectorización.

#	Paso	Decisión	Justificación
1	Entidades HTML (&#amp;#39;)	Se decodifican con <code>html.unescape</code>	El scraping dejó entidades que ensucian los n-gramas
2	URLs	Se eliminan; se guarda el conteo	La URL exacta no generaliza, pero su presencia sí es señal
3	Menciones @usuario	Se eliminan	Identifican cuentas, no el tema; provocan sobreajuste
4	Hashtags	Se quita el #, se conserva la palabra	#earthquake es contenido relevante
5	Emojis y emoticones	Se eliminan solo para el modelo; se cuentan aparte	Se analizan en el ejercicio 8
6	Caracteres mal codificados	Se eliminan	Ruido de codificación sin significado
7	Minúsculas	Sí	Evita duplicar tokens (Fire / fire)
8	Números	Se eliminan excepto 911 → num911	Cifras sueltas no generalizan (ver 2.1)
9	Puntuación y símbolos	Se eliminan	No aportan a un modelo bolsa-de-palabras

10	Stopwords	Se eliminan, conservando negaciones	not, never cambian el sentido
11	Tokens de un carácter	Se eliminan	Residuos de los pasos anteriores
12	Lematización	WordNetLemmatizer	Une <i>fires/fire, killed/kill</i> sin mutilar la palabra como un <i>stemmer</i> agresivo

Preprocesamiento bifurcado. Se construyó una segunda función, `limpiar_para_sentimiento()`, que conserva emoticones, puntuación y mayúsculas. No se usa en este avance, pero deja listo el insumo del ejercicio 8, donde el analizador de sentimiento sí aprovecha esas señales.

Resultado. El promedio de tokens por tweet bajó de 14.9 a 8.65, es decir se eliminó cerca del 42% de los tokens sin que ningún tweet quedara vacío (0 tweets con cero tokens tras limpiar). Un ejemplo de la transformación:

Original	Procesado
<i>So you have a new weapon that can cause un-imaginable destruction.</i>	new weapon cause unimaginable destruction

3. N-gramas: frecuencias y probabilidades (ejercicio 4)

Los n-gramas se generaron con `CountVectorizer`, por separado para cada categoría. Para cada uno se calculó:


- Frecuencia absoluta por clase.
- Probabilidad relativa $P(w|c) = \text{count}(w,c) / \sum \text{count}(w',c)$, con suavizado de Laplace ($\alpha = 1$) para evitar probabilidades cero en n-gramas que solo aparecen en una clase.
- Log-odds $\log[P(w|\text{desastre}) / P(w|\text{no desastre})]$, como medida de poder discriminante.
- Para bigramas, la probabilidad condicional $P(w_2|w_1) = \text{count}(w_1, w_2) / \text{count}(w_1)$, es decir el modelo de lenguaje bigrama de máxima verosimilitud (Jurafsky & Martin, cap. 3).

Se obtuvieron 3,874 unigramas y 2,323 bigramas con frecuencia total ≥ 3 , y 3,406 trigramas con frecuencia ≥ 2 . Que haya más trigramas que bigramas es consecuencia del umbral más bajo, y es en sí mismo evidencia de su dispersión: casi todos aparecen apenas dos o tres veces. Las tablas completas están en `tablas/tabla03_ngramas_*.csv`.

3.1 Palabras más frecuentes por categoría


La Figura 3 compara los 20 unigramas más frecuentes de cada clase. La palabra más repetida en desastre real es *fire* (265 apariciones) y en no-desastre *like* (255 apariciones). El contraste es ilustrativo: una es vocabulario de catástrofe, la otra es la muletilla conversacional más común del inglés (*look like, feel like*).

Figura 3. Top 20 unigramas por categoría



3.2 ¿Qué palabras servirán para un mejor modelo?

Las palabras útiles no son las más frecuentes sino las de log-odds extremo (Figura 4). Los quince unigramas más asociados a desastre real son:



Término	Frec. desastre	Frec. no-desastre	Log-odds
northern	64	0	4.30

legionnaire	62	0	4.27
debris	50	0	4.06
migrant	48	0	4.02
severe	47	0	3.99
hiroshima	91	1	3.95
derailment	41	0	3.86
investigator	37	0	3.76
mosque	36	0	3.73
mh	72	1	3.72
pkk	31	0	3.59
detonated	31	0	3.59
bomber	61	1	3.56
turkey	28	0	3.49
israeli	28	0	3.49

Se distinguen tres familias: vocabulario técnico de emergencia (debris, derailment, detonated, severe), entidades de eventos concretos (hiroshima, mh por el vuelo MH370, pkk, northern por los incendios del norte de California) y actores institucionales (investigator). La segunda familia es la que más conviene vigilar: son términos ligados a las noticias específicas de la ventana temporal en que se recolectó el dataset, así que discriminan perfectamente aquí pero no generalizarían a tweets de otro periodo. Los términos del extremo opuesto, asociados a no-desastre, se leen en el extremo verde de la Figura 4 y corresponden a vocabulario coloquial y de entretenimiento.

3.3 ¿Vale la pena explorar bigramas o trigramas?

Sí, los bigramas, y hay evidencia cuantitativa. El caso del unigrama fire lo ilustra: aparece 265 veces en desastre y 88 en no-desastre, con log-odds de solo 1.22 — es discriminante pero ambiguo, porque cubre tanto el incendio literal como el uso figurado. Al pasar a bigramas el contexto local desambigua:

Bigrama	Frec. desastre	Frec. no-desastre	Log-odds
rocky fire	9	0	2.37
wild fire	25	2	2.22
building fire	12	1	1.94
bush fire	17	2	1.86
forest fire	20	8	0.91
fire truck	10	9	0.16

El log-odds pasa de 1.22 en el unigrama a más del doble en varios bigramas, mientras que fire truck cae casi a cero. Los bigramas más discriminantes del corpus completo son suicide bomber (60/0),

northern california (41/0), california wildfire (36/0), suicide bombing (34/0) y severe thunderstorm (28/0). Por eso la vectorización del modelo usa `ngram_range=(1,2)`.

Los trigramas se descartaron como característica del modelo. Son en su mayoría extensiones redundantes de los mismos bigramas —suicide bomber detonated, northern california wildfire, pkk suicide bomber— con frecuencias de 25 a 30 y una dimensionalidad mayor. Aportan poca información nueva y aumentan el riesgo de sobreajuste, así que se calcularon y documentaron pero no se incluyeron.


3.4 Probabilidad condicional $P(w_2|w_1)$

El modelo de lenguaje bigrama muestra colocaciones muy fuertes en la clase de desastre: $P(\text{northern}|\text{razed}) = 0.933$, $P(\text{suicide}|\text{pkk}) = 0.903$ y $P(\text{spill}|\text{oil}) = 0.864$. En no-desastre dominan otras: $P(\text{video}|\text{liked}) = 0.919$ y $P(\text{body}|\text{cross}) = 0.864$, esta última de *cross body bag*, un accesorio — el mismo body bag que en contexto de desastre significaría algo muy distinto. Es otro argumento a favor de los bigramas.

4. Análisis exploratorio (ejercicio 5)

4.1 keyword

Resultó altamente informativa por sí sola. La Figura 5 la ordena por proporción de desastres reales. En el extremo superior hay palabras clave con tasa de 1.00 —derailment (39 tweets), debris (37), wreckage (39)— seguidas de outbreak (0.975), typhoon (0.974), oil spill (0.974) y suicide bombing (0.970). En el extremo inferior están términos que se usan casi siempre en sentido figurado. Como la tasa global es 0.43, estas keywords separan mucho mejor que el azar, y por eso se concatenó keyword al texto como entrada del modelo (sección 5.1).



4.2 location

Es un campo de texto libre sin normalizar: 3,341 valores distintos y 33.27% de faltantes. Conviven países, ciudades, estados y entradas que no son lugares reales (*Worldwide* aparece 19 veces). Las ubicaciones más frecuentes son USA (104), New York (71), United States (50) y London (45) — nótese que USA y United States son la misma entidad sin unificar.


Entre las que tienen al menos 15 tweets sí hay diferencias de tasa de desastre: Mumbai 0.864, India 0.833 y Nigeria 0.786 frente a New York 0.225 y Kenya 0.250. Pero con esa cardinalidad y esos faltantes, la variable se descartó como predictor y se conservó solo con fines descriptivos: cualquier modelo que la use estaría memorizando cadenas de texto específicas.

4.3 Nubes de palabras e histogramas

Las Figuras 6 y 7 muestran las nubes de palabras por categoría y del corpus completo, generadas con el módulo wordcloud.

[illegible]

Figura 8 presenta el histograma de las 25 palabras más frecuentes del corpus, desagregadas por categoría en barras apiladas, lo que permite ver de un vistazo cuáles son discriminantes y cuáles transversales.



4.4 Palabras presentes en todas las categorías

Filtrando los unigramas con al menos 15 apariciones en ambas clases y ordenando por log-odds absoluto, aparecen los términos verdaderamente transversales:

Término	Frec. desastre	Frec. no-desastre	Log-odds
life	59	67	-0.001
could	38	43	0.003
hijacking	15	17	0.006
china	20	23	-0.010
chemical	16	18	0.013
emergency	76	82	0.049
weapon	40	48	-0.055
fatality	34	36	0.068

El hallazgo interesante es que no todas son vocabulario genérico. emergency, weapon, fatality, hijacking y chemical suenan a vocabulario de catástrofe y sin embargo aparecen con frecuencia relativa idéntica en ambas clases: se usan igual de seguido en sentido figurado, en titulares de ficción o en conversación casual. Esto confirma que la presencia de vocabulario alarmante no basta para clasificar, que es exactamente lo que explica el patrón de errores de la sección 5.5.

Estas palabras se trataron de dos formas: las que además son stopwords ya se eliminaron en la sección 2, y para el resto TF-IDF las penaliza automáticamente al reducir su peso por alta frecuencia

documental. Se descartó eliminarlas a mano con una lista negra, porque TF-IDF resuelve el problema sin perder información y sin introducir una decisión arbitraria.

5. Modelo preliminar de clasificación (*ejercicio 6*)

5.1 ¿Cómo se aborda el contexto?

Un modelo bolsa-de-palabras pierde el orden y con él el contexto. Se ataca en cuatro niveles; los tres primeros están implementados en este avance:

1. N-gramas (1,2) en la vectorización, que recuperan contexto local y desambiguan los usos figurados documentados en 3.3.
2. TF-IDF en lugar de conteos crudos, que baja el peso de los términos ubicuos de 4.4.
3. keyword concatenada al texto, contexto temático ya anotado en el propio dataset y que la sección 4.1 mostró altamente predictivo.
4. Variable de sentimiento (*ejercicio 10, entrega final*), rasgo semántico independiente del vocabulario exacto que ayudaría en los casos figurados.

Queda documentada una quinta ruta, fuera del alcance del laboratorio: *embeddings* contextuales tipo BERT, que modelan el orden completo de la oración.

5.2 Protocolo experimental

Partición estratificada 80/20 con `random_state=42`: 6,090 tweets de entrenamiento y 1,523 de prueba, con proporción de desastres de 0.4297 y 0.4294 respectivamente — la estratificación funcionó. La selección se hizo por validación cruzada estratificada de 5 pliegues sobre el conjunto de entrenamiento; el de prueba se reservó intacto hasta la evaluación final. Vectorización: `TfidfVectorizer(ngram_range=(1,2), min_df=2, max_df=0.9, sublinear_tf=True)`.

5.3 Algoritmos y parámetros

Modelo	Parámetros	Razón de inclusión
Naïve Bayes multinomial	<code>alpha=0.5</code>	Línea base clásica en texto; asume independencia entre términos
Regresión logística	<code>C=5.0, max_iter=2000</code>	Coefficientes interpretables; fuerte en alta dimensión dispersa
SVM lineal	<code>LinearSVC(C=0.5)</code> calibrado con <code>CalibratedClassifierCV</code>	Suele ser el mejor en texto disperso; se calibra para obtener probabilidades
Random Forest	<code>n_estimators=400, min_samples_leaf=2</code>	Contraste no lineal; captura interacciones entre términos


5.4 Resultados preliminares

Tabla 5. Comparación de los cuatro modelos:

Modelo	F1 (CV)	sd CV	Accuracy	Precisión	Recall	F1 (test)	ROC-AUC
SVM lineal	0.7434	0.0081	0.8194	0.8174	0.7462	0.7802	0.8707
Regresión logística	0.7412	0.0074	0.8175	0.8133	0.7462	0.7783	0.8676
Naive Bayes multinomial	0.7391	0.0059	0.8201	0.8571	0.6972	0.7690	0.8711
Random Forest	0.7327	0.0163	0.8089	0.8081	0.7278	0.7659	0.8607


El modelo preliminar seleccionado es el SVM lineal, con F1 de 0.7802 y exactitud de 0.8194 en el conjunto de prueba, frente a la línea base trivial de 0.5703. La Figura 9 muestra su matriz de confusión y las curvas ROC de los cuatro modelos.

Figura 9. Desempeño de los modelos de clasificación



Dos observaciones sobre la tabla. Primero, los cuatro modelos quedan muy juntos: 0.011 separa el mejor F1 del peor, y las desviaciones de la validación cruzada (0.006–0.016) son del mismo orden que las diferencias entre modelos. La selección es por lo tanto poco robusta, y conviene decirlo en vez de presentar al SVM como claramente superior. Segundo, Naive Bayes tiene la mayor exactitud (0.8201) y el mayor ROC-AUC (0.8711) pero el peor F1 de los tres lineales: su precisión es la más alta (0.8571) a costa del recall más bajo (0.6972), es decir es conservador al declarar desastre. Con clases desbalanceadas la exactitud favorece ese comportamiento, y es la razón por la que se seleccionó por F1 y no por exactitud.

La Figura 10 presenta los términos de mayor peso en la regresión logística, que coinciden con los de log-odds extremo de la Figura 4 — verificación de que el modelo aprendió señal real y no artefactos del preprocesamiento.



La selección definitiva del mejor modelo se hará en la entrega final, ya con la variable de negatividad del ejercicio 10 incorporada.

5.5 Análisis de errores

El modelo falló en 275 de 1,523 tweets de prueba (18.06%), con un patrón claro en ambas direcciones.

Falsos positivos — no era desastre, se predijo desastre:

- «*slicker than an oil spill*» (keyword oil spill): símil coloquial.
- «*Ignition Knock (Detonation) Sensor-Senso Standard...*» (keyword detonation): un anuncio de repuestos automotrices; detonation aquí es término técnico de motores.
- «*if firefighters acted like cops they'd drive a...*» (keyword burning buildings): comentario social hipotético.

Falsos negativos — era desastre, se predijo no desastre:

- «*Hollywood Movie About Trapped Miners Released...*» (keyword trapped): habla de un desastre real pero en registro de nota de entretenimiento.
- «*I can't drown my demons they know how to swim*» (keyword drown): metáfora etiquetada como desastre en el dataset — un caso donde la etiqueta original es discutible.
- «*We need these plants in the pacific du...*» (keyword cyclone): sin vocabulario explícito de catástrofe.

Ambos grupos apuntan a la misma limitación —el contexto— y son consistentes con el hallazgo de 4.4: el vocabulario alarmante se distribuye por igual entre las clases. Los falsos positivos son

mayormente usos figurados, técnicos de otro dominio o hipotéticos; los falsos negativos, desastres reales narrados en registro no noticioso. Esto motiva la variable de sentimiento del ejercicio 10, que se desarrolla en la entrega final.

Referencias

Jurafsky, D., & Martin, J. H. *Speech and Language Processing* (3.^a ed.). Capítulo de N-gramas. <https://web.stanford.edu/~jurafsky/slp3/>

Feinerer, I., Hornik, K., & Meyer, D. (2008). Text Mining Infrastructure in R. *Journal of Statistical Software*, 25(5), 1–54.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media (NLTK).

Kaggle. *Natural Language Processing with Disaster Tweets*. <https://www.kaggle.com/competitions/nlp-getting-started>